三大要素

第 03 讲 · 2026 年 9 月 8 日

layout: default

第 2 周 · 环境检查

`aider-practice` 状态

- 模型服务运行了吗？
- Aider 能连接到它吗？
- 环境障碍：权重拉不下来、服务器 Aider 连不上、机器太小？

本周随时答疑，我们任何人都可以帮你做环境设置。**9 月 11 日周五**是环境检查和全部十六节课的截止日期。

layout: section

三大要素

上下文 · 模型 · 提示词

layout: default

三个杠杆

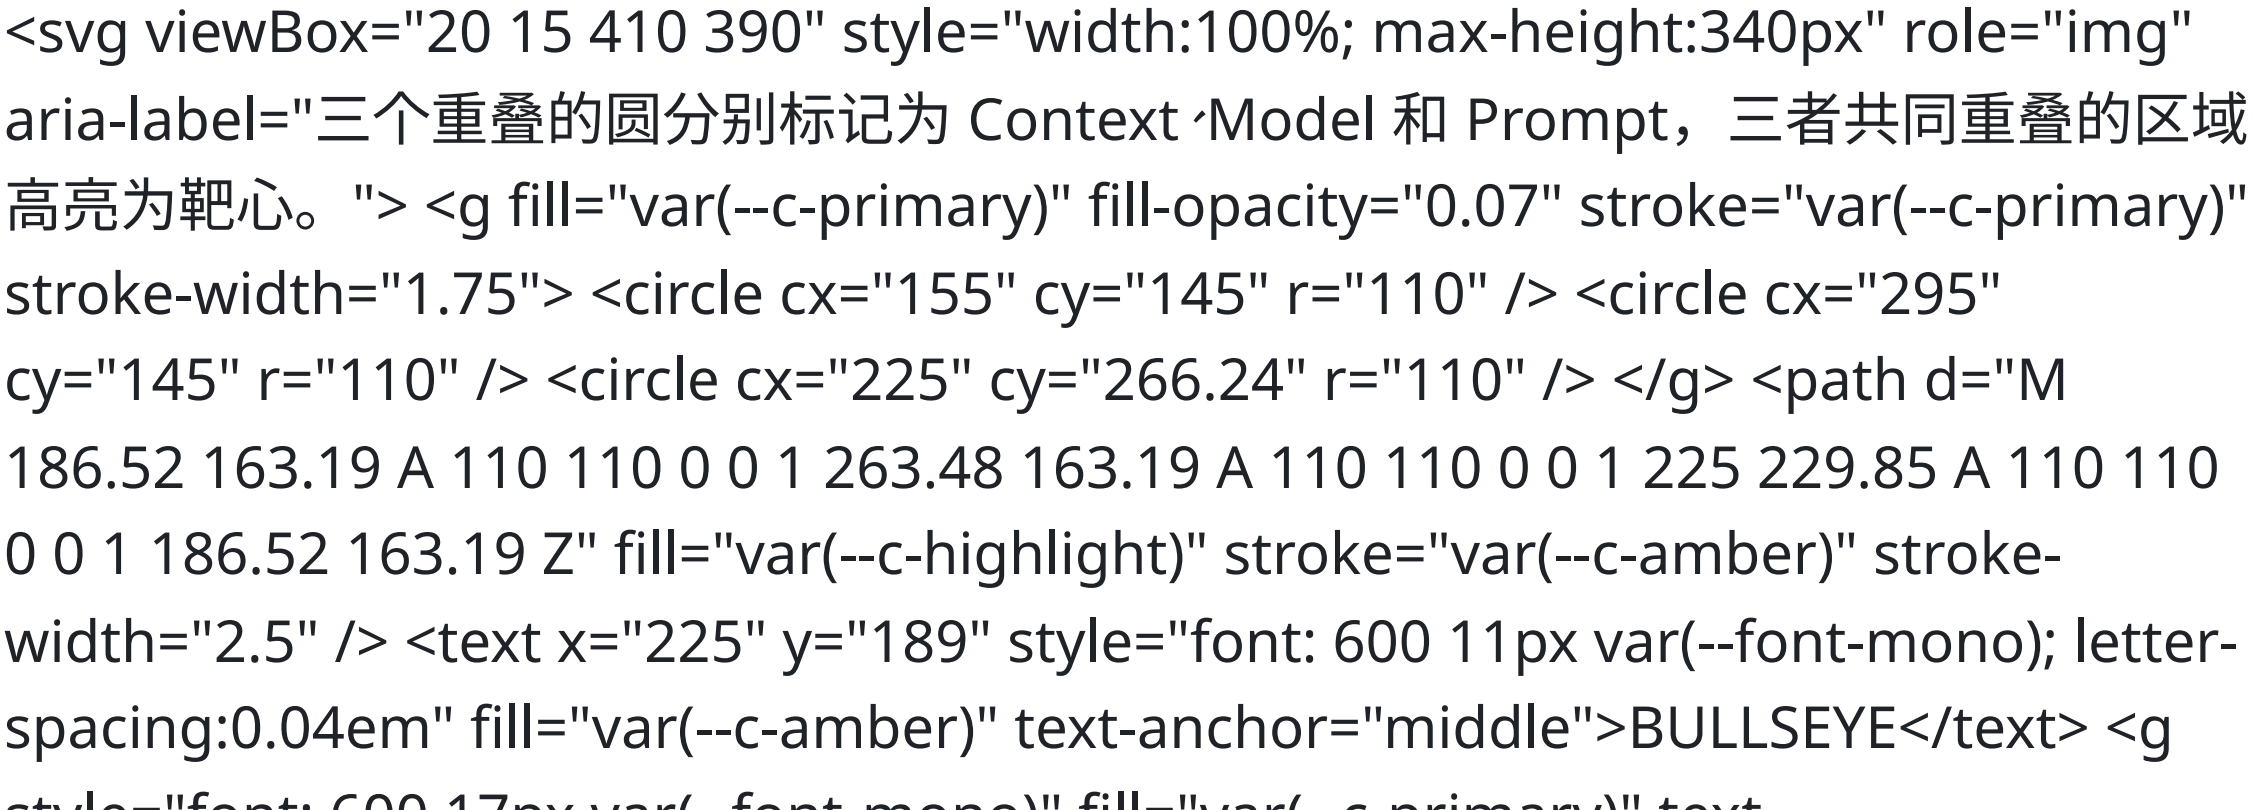
每一次 AI 编程会话

<ph-files-bold class="text-3xl text-blue-600 mb-3" />
上下文
模型现在能看到什么？
<ph-cpu-bold class="text-3xl text-blue-600 mb-3" />
模型
用哪个 LLM？能力 + 知识。
<ph-chat-bold class="text-3xl text-amber-600 mb-3" />
提示词
意图表达得有多清楚？

layout: default

靶心

三者的重叠区域



layout: statement

三中取二*不够*。

layout: default

当 AI 出错时，依次询问

诊断

1. **上下文** —— 文件在窗口中吗？
2. **模型** —— 它足够强大吗？足够新吗？
3. **提示词** —— 意图清楚吗？

大多数学生责怪模型。这通常不是原因。

layout: section

上下文

你能最直接控制的杠杆

layout: default

四个来源

你的上下文里有什么

<v-clicks>

- **显式添加的文件** —— 你 `/add` 的内容
- **代码库地图** —— 自动生成的结构摘要
- **聊天历史** —— 积累到 `/clear`
- **系统提示词** —— Aider 给模型的指令

</v-clicks>

layout: statement

全部添加进来比添加正确的内容*更差*。

layout: default

技能

外科手术式上下文

<ph-pencil-simple-bold class="text-3xl text-blue-600 mb-3" />
更改
这个任务会编辑哪些文件？只有这些文件能被编辑。
<ph-eye-bold class="text-3xl text-blue-600 mb-3" />
读取
它必须先理解哪些文件？也添加这些。
<ph-bookmark-simple-bold class="text-3xl text-amber-600 mb-3" />
参考
只读背景。通常代码库地图已经覆盖了。
只添加这些。`/drop`其他的。经常用`/tokens`。上下文是设计，不是设置

layout: default

阅读预算

你的 tokens 去哪了

```
/tokens

  repo map               1,800
  chat history           3,100
  main.py                6,000
  arg_parse.py           1,300
  ---------------------------
  total                 12,200   of 32,768
```

在任何大操作之前和之后检查它。这是对窗口唯一诚实的视图。

layout: default

两个陷阱

学生卡住的地方

<ph-file-x-bold class="text-3xl text-rose-600 mb-3" />
缺失上下文
arg_parse.py 没有被 /add → 模型只编辑 main.py → 结果损坏。
<ph-clock-counter-clockwise-bold class="text-3xl text-rose-600 mb-3" />
聊天历史渗透
任务 B 继承了任务 A 的假设。修复方法：/clear。

layout: statement

聊天休息 · 5 分钟

十个文件，一个函数要改，三个调用者。你如何决定添加什么？讨论你的策略。

layout: section

模型

将能力与任务匹配

layout: default

四个维度

选择

<v-clicks>

- **推理能力** —— L02 中的能力
- **速度** —— 通常与能力相关
- **成本** —— 供应商那里的美元，自己机器上的 RAM 和秒数
- **上下文窗口大小** —— 但更大 ≠ 更好（L02！）

</v-clicks>

layout: default

工程问题

这份工作的合适模型

<ph-wrench-bold class="text-3xl text-blue-600 mb-3" />
单行 bug 修复
一个便宜、快速的模型就能过线。在这里花费能力什么都买不到。
<ph-tree-structure-bold class="text-3xl text-amber-600 mb-3" />
三个新文件，相互依赖
你拥有的最强大的模型。做错的代价超过这次调用的成本。
基准测试（`aider.chat/docs/leaderboards/`）可以代理你的任务。它们不能替代它。

layout: default

应用经验法则

从会失败的模型开始

- **从 4b 开始。** 它在你能看到的地方失败，失败就是课程
- **当它停止教你，只是浪费你一个下午时，切换到 9b**

一个能掩盖你错误的模型 *隐藏了你需要看到的错误。*
用 `/model ollama_chat/qwen3.5:9b` 切换。文件和历史记录保留；新模型重新读取所有内容。

layout: section

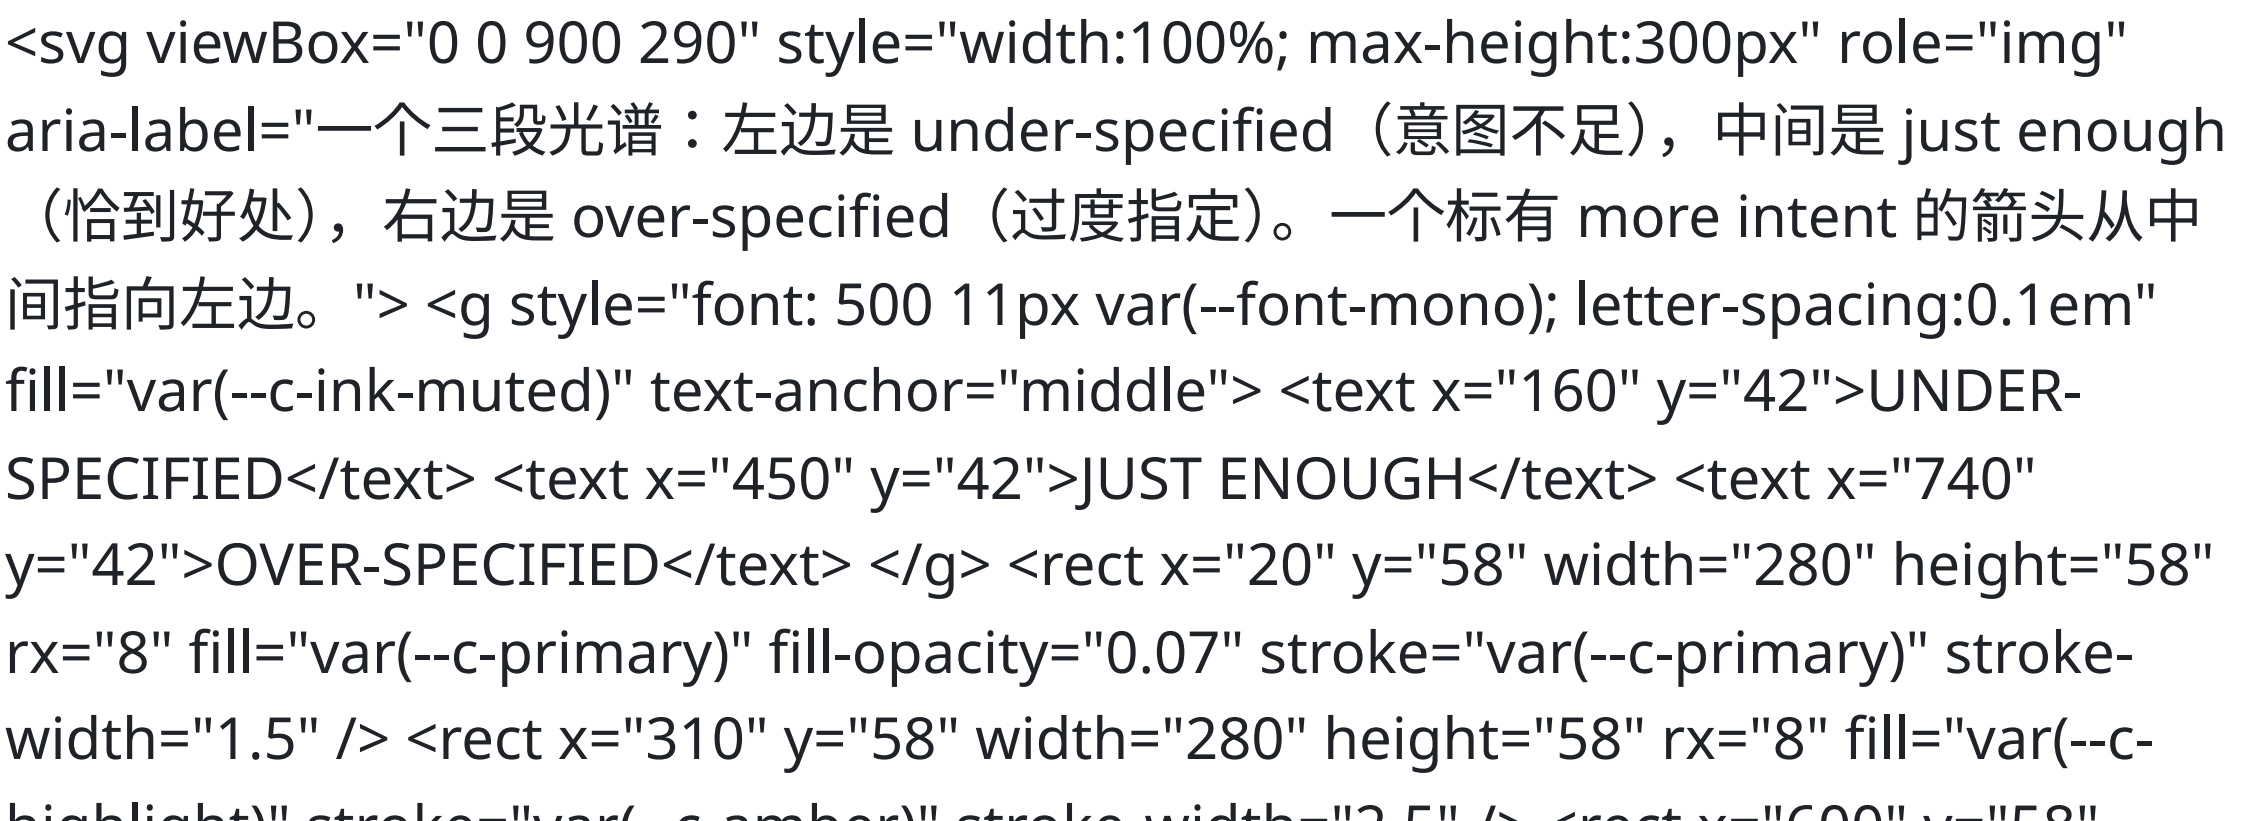
提示词

精确表达意图

layout: default

提示词光谱

具体化程度



layout: two-col

模糊

```
Add another way
to output the data.
```

模型猜测。也许是文本。也许是 print()。可能跳过 CLI 标志。不可预测。

::right::

具体

```
CREATE output_format.py:
  format_as_html(...) -> str
UPDATE main.py: ADD
  html to --output-format
```

可预测。可重复。一次成功。

layout: statement

What > How ◦

layout: default

映射回 L02

每个杠杆都有一个底层原理

- **上下文** → 上下文窗口经济。更大不是免费的。
- **模型** → 能力 vs 知识维度。
- **提示词** → 缩小采样分布。

三大要素不是随意的。它是底层原理之上的框架。

layout: section

现场演示

上下文作为工程决策

layout: default

5 文件转录分析代码库

演示流程

<v-clicks>

1. 只用 `src/main.py` 运行 Aider。提示词：`--output-format` 标志。
2. 它提议重写 `arg_parse.py`，一个它从未读过的文件。拒绝。
3. 运行程序。干净的 diff，`AttributeError`。然后 `/undo`。
4. `/add src/arg_parse.py`。相同的提示词。连贯了，而且能运行。
5. `/tokens`：聊天历史是最大的一行，比全部五个文件都大。
6. `/model ollama_chat/qwen3.5:4b`，`/clear`，`/drop`，`/add src/main.py`。相同的提示词。

layout: default

带回家

三个问题

1. 50 文件项目，跨 API 层更改认证 —— 你如何 /add？
2. 为什么添加**所有**文件会让结果*更差*？
3. 会话中切换模型 —— 什么改变了？

大多数"AI 错了"的故障都归结为问题 1 或 2。

layout: default

三大要素

要点总结

- **上下文、模型、提示词。** 三个杠杆，你ever运行的每个会话
- **上下文通常是问题所在。** 大多数"AI 错了"是缺失上下文
- **模型选择是技术性的**，不是偏好。将能力与任务匹配
- **提示词说 What，不是 How。**命名文件、命名函数、说明结果

三中取二不够。在重写提示词之前先问这个问题。

layout: default

接下来

Lab01 + 构建项目

<v-clicks>

- **9 月 11 日周五** —— 环境检查，全部十六节课截止
- **9 月 14 日周一 / 9 月 15 日周二** —— Lab01：转折实验课
- **构建项目** —— 七个功能，第 3 和第 4 周。Lab01 之后开始，规格随它一起评分
- **L04 9 月 10 日周四** —— 规格驱动编程，两天后

</v-clicks>

在 Lab01 出问题时使用今天的诊断。*上下文、模型，还是提示词？*

layout: end